

Seminar 5

Eric

15 4 2021



I dag skal vi se på fem ting:

1. Laste inn data (repetisjon)
2. Omkoding av variabler (repetisjon)
3. Plotting (repetisjon)
4. Kjøre en regresjonsmodell med en uavhengig variabel (nytt)
5. Tolkning og fremstilling av regresjonsresultater (nytt)

Datasettet vi skal bruke er det samme som det som omtales i kapittel ni i The Fundamentals of Political Science Research. I likhet med kapittel ni så skal vi kjøre en regresjon der vi ser på effekten av økonomisk vekst (`growth`) på andel stemmer partiet til den sittende kandidaten får (`inc_vote`).

```
# Laster inn pakker
library(tidyverse)
library(stargazer)

#En ting vi kan gjøre her er å sette et fast tema for alle plottene våre, da
#trenger vi ikke gjøre det hver gang vi bruker ggplot
theme_set(theme_classic())

EcoData <- read.csv("https://raw.githubusercontent.com/egen97/STV1020_Var_2021/master/ecoData.csv")
```

Undersøker data

Når vi skal kjøre en regresjonsanalyse så er noe av det første vi gjør å undersøke datasettet:

```
# Hent ut informasjon om variabelnavn, klasse m.m.
str(EcoData)

## 'data.frame': 36 obs. of 5 variables:
## $ inc_vote : num 48.5 50.2 49.8 50.4 48.3 ...
## $ year : int 1876 1880 1884 1888 1892 1896 1900 1904 1908 1912 ...
## $ inflation: num NA 1.974 1.055 0.604 2.274 ...
## $ goodnews : int NA 9 2 3 7 6 7 5 8 8 ...
## $ growth : num 5.11 3.88 1.59 -5.55 2.76 ...
```

```
# Et alternativ til str()
EcoData
```

```
##      inc_vote year inflation goodnews growth
## 1      48.516 1876         NA         NA  5.110
## 2      50.220 1880      1.974          9  3.879
## 3      49.846 1884      1.055          2  1.589
## 4      50.414 1888      0.604          3 -5.553
## 5      48.268 1892      2.274          7  2.763
## 6      47.760 1896      3.410          6 -10.024
## 7      53.171 1900      2.548          7 -1.425
## 8      60.006 1904      1.442          5 -2.421
## 9      54.483 1908      1.879          8 -6.281
## 10     54.708 1912      2.172          8  4.164
## 11     51.682 1916      4.252          3  2.229
## 12     36.148 1920      0.000          0 -11.463
## 13     58.263 1924      5.161         10 -3.872
## 14     58.756 1928      0.183          7  4.623
## 15     40.851 1932      6.928          4 -14.350
## 16     62.226 1936      2.498          9 11.682
## 17     54.983 1940      0.051          8  3.913
## 18     53.778 1944      0.000          0  4.122
## 19     52.319 1948      0.000          0  3.214
## 20     44.710 1952      2.353          7  0.997
## 21     57.094 1956      1.907          5 -1.252
## 22     49.913 1960      1.980          5  0.674
## 23     61.203 1964      1.241          9  5.030
## 24     49.425 1968      3.086          7  5.045
## 25     61.791 1972      4.813          4  5.834
```

```
## 26 48.951 1976 7.463 5 3.817
## 27 44.842 1980 7.795 5 -3.583
## 28 59.123 1984 5.210 8 5.550
## 29 53.832 1988 2.871 5 2.403
## 30 46.379 1992 3.193 3 3.035
## 31 54.737 1996 2.031 4 3.315
## 32 50.262 2000 1.683 7 2.031
## 33 51.233 2004 2.141 2 2.086
## 34 46.311 2008 2.745 2 -1.787
## 35 52.010 2012 1.470 1 1.422
## 36 51.111 2016 1.420 2 0.970
```

```
# Printer variabelnavnene
```

```
names(EcoData)
```

```
## [1] "inc_vote" "year" "inflation" "goodnews" "growth"
```

```
# Henter ut oppsummerende statistikk:
```

```
summary(EcoData)
```

```
##      inc_vote      year      inflation      goodnews
##  Min.   :36.15  Min.   :1876  Min.    :0.000  Min.    : 0.000
## 1st Qu.:48.84 1st Qu.:1911 1st Qu.:1.431 1st Qu.: 3.000
## Median :51.46 Median :1946 Median :2.141 Median : 5.000
## Mean   :51.93 Mean   :1946 Mean   :2.567 Mean   : 5.057
## 3rd Qu.:54.80 3rd Qu.:1981 3rd Qu.:3.139 3rd Qu.: 7.000
## Max.   :62.23 Max.   :2016 Max.   :7.795 Max.   :10.000
##
##      NA's      :1      NA's      :1
##
##      growth
##  Min.   : -14.3500
## 1st Qu.: -1.5155
## Median :  2.1575
## Mean   :  0.7635
## 3rd Qu.:  3.9653
## Max.   : 11.6820
##
```

Det er også lurt å sjekke om mange observasjoner har manglende informasjon (missing) på variablene du er interessert i:

```
# Sjekker hvor mange observasjoner som vi har informasjon på alle variablene om:
```

```
table(complete.cases(EcoData))
```

```
##
## FALSE TRUE
##      1   35
```

Vi ser at 35 av observasjonene våre ikke har noen missingverdier. Vi kan også sjekke for enkeltvariabler:

```
# Sjekker hvor mange observasjoner som har missing på variabelen inflation
```

```
table(is.na(EcoData$inflation))
```

```
##
## FALSE TRUE
##     35    1
```

Vi ser at en observasjon har missing på variabelen `inflation`.

Legg merke til at funksjonene `complete.cases()` og `is.na()` er logiske tester. Disse evaluerer hver observasjon

og sjekker om vi har informasjon om alle variabler (`complete.cases()`) og om vi mangler informasjon på variabelen `inflation`. For å illustrere dette så kan vi prøve å legge til to nye variabler i datasettet basert på disse logiske testene:

```
EcoData <- EcoData %>%
  mutate(complete = complete.cases(.),
         inf_na = is.na(inflation))
```

Bruk `view()` eller klikk på datasettet ditt for å se hvordan de nye variablene ser ut. Hva betyr `TRUE` og `FALSE` i de to kolonnene?

Mer informasjon om missingverdier finner dere i dokumentet som beskriver seminar 4.

Omkoding av variabler

Etter at vi har kartlagt datastrukturen og hvilke variabler vi har så må vi vurdere om noen av variablene må omkodes før vi kan gjøre analysen vår. For å få samme resultater som i kapittel ni trenger vi ikke å omkode noe, men for å få noe å sammenligne med skal vi lage en dikotom variabel.

I `tidyverse` bruker man som regel `mutate()` sammen med andre funksjoner for å opprette nye variabler. Koden over hvor vi opprettet variabler for de logiske testene `complete.cases()` og `is.na()` er eksempler på dette. Nå skal vi også kombinere `mutate()` med `ifelse` for å lage en dikotom variabel som tar verdien `Growth` om observasjonen er et år med positiv økonomisk vekst og `No growth` om observasjonen er et år uten økonomisk vekst:

```
# Oppretter den nye variabelen og endrer referansekategori
EcoData <- EcoData %>%
  mutate(growth_dich = ifelse(growth > 0, "Growth", "No growth"),
         growth_dich = factor(growth_dich, levels = c("No growth", "Growth")))
```

Hvordan `ifelse()` fungerer er nærmere beskrevet i seminar 3. Det neste vi gjør er å sjekke om omkodingen ble riktig:

```
# Sjekker at det ser ok ut:
class(EcoData$growth_dich)
```

```
## [1] "factor"
```


```
table(EcoData$growth_dich, useNA = "always")
```

```
##
## No growth    Growth    <NA>
##          11         25         0
```

Når du lager en faktor-variabel så tar R utgangspunkt i alfabetet når referansekategorien bestemmes. I dette tilfellet ville referansekategorien blitt “Growth”, men vi bruker `factor()` til å endre referansekategorien til “No growth”.

Når en omkoder numeriske variabler så kan det være nyttig å lage et plott for å sjekke at det ble riktig. Her bruker vi `fill` argumentet til å gi ulik farge til observasjonene basert på om det var vekst eller ikke:

```
ggplot(data = EcoData) +
  geom_bar(aes(x=growth, fill = growth_dich),
           binwidth = 1) +
  theme(legend.title=element_blank()) +
  xlab("Growth rate") +
  ylab("No. of observations")
ggsave("Bilder/growth.jpg") #Med ggsave kan jeg lagre plottet, så jeg f.eks. kan putte det i en word-fi
```




Ut fra plottet kan vi se at alle observasjonene med verdien **No growth** hadde negativ vekstrate, mens alle observasjoner med verdien **Growth** hadde positiv vekstrate.

For å lagre plottet lokalt på pc-en så kan bruker export og save as under Plots.

Litt plotting før regresjon


Før du kjører en regresjon så kan det være lurt å plote den avhengige og den uavhengige variabelen din. I vårt tilfelle er dette variabelene **inc_vote** og **growth**. For å få til dette bruker vi **ggplot**.

```
ggplot(data = EcoData) +
  geom_point(aes(x = growth, y = inc_vote)) +
  ylab("Incumbent-Party Vote Percentage") +
  xlab("Percentage change in Real GDP Per Capita")
```



```
ggsave("RegPlotGrInc.jpg")
```

```
## Saving 6.5 x 4.5 in image
```



Regresjon med numerisk uavhengig variabel



For å kjøre en lineær regresjon i R så bruker vi funksjonen `lm()`. `lm()` har følgende syntaks:

```
lm(avhengig_variabel ~ uavhengig_variabel, data = mitt_datasett)
# På mac får du ~ med alt + k + space
```

Dersom datasettet ditt har manglende informasjon (missing/NA) så må du legge til et element som sier hvordan regresjonen skal forholde seg til dette. Ved å legge til `na.action = "na.exclude"` i `lm()` så beholder R informasjon om hvilke observasjoner som mangler data slik at vi kan bruke `fitted()` som vi skal snakke mer om senere.

I eksempelet fra kapittel ni i Kellsted og Whitten er vi interessert i effekten av den uavhengige variabelen `growth` på den avhengige variabelen `inc_vote`. Under kjører vi modellen og lagrer den som `model` i Environment:

```
model <- lm(inc_vote ~ growth,
            data = EcoData,
            na.action = "na.exclude")
```

Det finnes flere måter å undersøke resultatene på. Vi skal se på hvordan vi kan gjøre dette ved hjelp av `summary()`, `stargazer()` og `ggplot()`. Vi skal først se på `summary()`.


```
summary(model)
```

```
##
## Call:
## lm(formula = inc_vote ~ growth, data = EcoData, na.action = "na.exclude")
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -8.1384 -3.7445 -0.6354  2.8291 10.0700
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  51.4486     0.8133  63.256 < 2e-16 ***
## growth       0.6248     0.1550   4.032 0.000295 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.828 on 34 degrees of freedom
## Multiple R-squared:  0.3235, Adjusted R-squared:  0.3036
## F-statistic: 16.26 on 1 and 34 DF,  p-value: 0.0002955
```

stargazer() er en nyttig funksjon som gir oss samme informasjon som summary(), men i et litt mer lettlest format.

```
stargazer(model,
           type = "text")
```

```
##
## =====
##                      Dependent variable:
##                      -----
##                      inc_vote
##                      -----
## growth                0.625***
##                      (0.155)
##
## Constant              51.449***
##                      (0.813)
##
## -----
## Observations                36
## R2                        0.323
## Adjusted R2                0.304
## Residual Std. Error      4.828 (df = 34)
## F Statistic              16.256*** (df = 1; 34)
## =====
## Note:                      *p<0.1; **p<0.05; ***p<0.01
```

Ved hjelp av stargazer så kan vi også lagre tabeller lokalt på PC-en som vi kan bruke i word-dokumenter og liknende. Da endrer vi på type argumentet og legger til et out argument. out argumentet forteller i hvilken mappe du vil lagre filen samt hva filen skal hete. Da får du en .htm-fil som ser omtrent ut som i eksempelet under. Den kan du høyreklikke på og velge åpne i word dersom du skal ha tabellen inn i en oppgave eller liknende:

```
stargazer(model,
           type = "html",
```


```
out = "modell1_tab.htm")
```

Informasjonen vi får ved hjelp av `summary()` og `stargazer()` er veldig nyttig. Vi får vite koeffisientene, standardfeilene og informasjon vi kan bruke til å evaluere modellen vår. I seminar skal vi bruke en del tid på å tolke disse tabellene.

Et alternativ til tabeller er å plote resultatene fra regresjonen. Nå skal vi lage figur 9.4 i kapittel ni ved hjelp av `ggplot()`.

Først lager vi et plott med de observerte verdiene (dette er det samme plottet som vi lagde tidligere):

```
ggplot(data = EcoData) +  
  geom_point(aes(x = growth, y = inc_vote)) +  
  theme_bw() +  
  ylab("Incumbent-Party Vote Percentage") +  
  xlab("Percentage change in Real GDP Per Capita")
```




Det neste vi skal gjøre er å legge til regresjonslinjen i plottet. Dette kan gjøres på to måter.

Legge til regresjonslinje med `geom_smooth`

Den første måten er å bruke `geom_smooth(method = "lm")` for å plote en regresjonslinje:

```
ggplot(data = EcoData) +  
  geom_point(aes(x = growth, y = inc_vote)) +  
  ylab("Incumbent-Party Vote Percentage") +  
  xlab("Percentage change in Real GDP Per Capita") +  
  geom_smooth(aes(x = growth, y = inc_vote),
```


```
method = "lm", color = "goldenrod3")
ggsave("GRlin.jpg")
```



I kapittel ni viser Kellstedt og Whitten at regresjonslinjen krysser utvalgets gjennomsnittsverdier på uavhengig og avhengig variabel. Det kan vi også vise ved å legge til to linjer i koden vår:

```
ggplot(data = EcoData) +
  geom_point(aes(x = growth, y = inc_vote)) +
  ylab("Incumbent-Party Vote Percentage") +
  xlab("Percentage change in Real GDP Per Capita") +
  geom_smooth(aes(x = growth, y = inc_vote),
    method = "lm", color = "goldenrod3") +
  geom_hline(yintercept=mean(EcoData$inc_vote), linetype = "dashed") +
```

```
geom_vline(xintercept=mean(EcoData$growth), linetype = "dashed")
ggsave("Bilder/meansreg.jpg")
```



Legge til regresjonslinje med `fitted()` og `geom_line()`

Den andre metoden er å be R løse regresjonslikningen for alle observasjonene våre og så legge til et nytt lag med predikerte verdier i plottet. Denne metoden går vi ikke gjennom i detalj på seminar så det holder i massevis å kunne den første.

R kan regne ut de predikerte verdiene for oss ved hjelp av funksjonen `fitted()` så vi slipper heldigvis å gjøre det for hånd.


Her bruker vi funksjonene `fitted()` og `resid()` til å legge til predikerte verdier og residualer for de ulike variablene i datasettet vårt:

```
EcoData <- EcoData %>%
  mutate(fitted = fitted(model),
         residuals = resid(model))
```

Nå kan vi bruke denne informasjonen til å legge til en regresjonslinje i plottet vårt. Prikkene angir de ulike *observerte* verdikombinasjonene, mens den rette linjen gir oss den lineære sammenhengen fra modellen vår.


```
ggplot(data = EcoData) +
  geom_point(aes(x = growth, y = inc_vote)) +
  ylab("Incumbent-Party Vote Percentage") +
  xlab("Percentage change in Real GDP Per Capita") +
  geom_line(aes(x = growth, y = fitted))

ggsave("Bilder/FittedValues.jpg")
```



Også her kan vi vise at regresjonslinjen krysser utvalgets gjennomsnittsverdier på uavhengig og avhengig variabel. Vi legger til de to linjene `geom_hline()` og `geom_vline()`:

```
ggplot(data = EcoData) +  
  geom_point(aes(x = growth, y = inc_vote)) +  
  ylab("Incumbent-Party Vote Percentage") +  
  xlab("Percentage change in Real GDP Per Capita") +  
  geom_line(aes(x = growth, y = fitted)) +  
  geom_hline(yintercept=mean(EcoData$inc_vote), linetype = "dashed") +  
  geom_vline(xintercept=mean(EcoData$growth), linetype = "dashed")  
  
ggsave("FittedMean.jpg")
```



I kapittel ni i Kellstedt og Whitten er det flere eksempler på hvordan vi kan sjekke om en modell er god eller ikke. Noe av det gikk vi gjennom når vi så på resultatene av modellen. En ting som ikke kommer med når vi

bruker `stargazer()` og `summary()` er konfidensintervallene til en koeffisient. De kan vi enkelt hente ut ved hjelp av funksjonen `confint()`:

```
confint(model)
```

```
##                2.5 %      97.5 %  
## (Intercept) 49.7957308 53.1015677  
## growth      0.3098843  0.9397437
```

Regresjon med dikotom uavhengig variabel

For å øve oss på tolkning skal vi nå kjøre en modell med `inc_vote` som avhengig variabel og den dikotome vekst-variabelen vi lagde tidligere som uavhengig variabel. At en variabel er dikotom betyr at den bare har to verdier. Først kjører vi modellen før vi undersøker resultatene i `stargazer`:

```
# Lagrer modellen  
model_dich <- lm(inc_vote ~ growth_dich,  
                 data = EcoData,  
                 na.action = "na.exclude")
```

```
# Undersøker resultatene  
stargazer(model_dich,  
           type = "text")
```

```
##  
## =====  
##                Dependent variable:  
##                -----  
##                inc_vote  
## -----  
## growth_dichGrowth          2.859  
##                          (2.066)  
##  
## Constant                   49.940***  
##                          (1.722)  
## -----  
## Observations                36  
## R2                          0.053  
## Adjusted R2                 0.025  
## Residual Std. Error        5.711 (df = 34)  
## F Statistic                 1.914 (df = 1; 34)  
## =====  
## Note:                       *p<0.1; **p<0.05; ***p<0.01
```